

AP2 · ETAPA DE CLASSIFICAÇÃO

SmartShop AI

Sistema Inteligente de Recomendação de Produtos

Guilherme Wendelstein

Fundamentos de Inteligência Artificial

Problema e objetivo

O SmartShop AI ajuda a loja a identificar quais clientes têm maior chance de **comprar de novo**. Nesta etapa, isso é previsto com um modelo de classificação.

Tipo de problema: classificação binária.

Classe 0

Não comprou novamente

Classe 1

Comprou novamente

O que mudou desde a AP1

Antes	Agora	Por quê
Sem recência	Recência: dias desde a última compra	Mostra há quanto tempo não compra
Vários países	Reino Unido e Outros	Menos colunas no modelo
get_dummies antes do split	get_dummies depois do split	Teste não influencia a transformação
Uma árvore	Segunda árvore (profundidade 3)	Comparar com um modelo mais simples
Acurácia	Precision, recall, F1 e matriz	Ver que tipos de erro acontecem
Acurácia	Recall como métrica principal	Custo dos erros

Acurácia: 73,15% (Atividade 9) → 72,40% (revisada). Processo mais rigoroso e modelo mais simples.

Dados

Fonte

Online Retail · UCI Machine Learning Repository

Licença

CC BY 4.0

Período

01/12/2010 a 09/12/2011

Tamanho

Antes: 541.909 linhas × 8 colunas

Depois: 392.692 linhas × 8 colunas

3.985 clientes no modelo

Variável	O que representa
QuantidadeTotal	Total de unidades compradas
PrecoMedio	Preço médio dos itens
QuantidadePedidos	Número de pedidos do cliente
Pais	Reino Unido ou Outros
Recencia	Dias desde a última compra até a data de corte
Alvo	0 = não comprou novamente · 1 = comprou novamente

Tabela: características usadas no modelo e o alvo. Cada linha é um cliente.

Preparação dos dados

1. Limpeza da base

Feita na Atividade 8

- Valores ausentes tratados
- Duplicatas exatas removidas
- Cancelamentos tratados
- Valores não positivos tratados

2. Para o modelo

Uma linha por cliente

- Data convertida para o formato de data
- Países agrupados: Reino Unido ou Outros
- Recência criada
- Características calculadas por cliente

3. Cuidado com vazamento

Passado × futuro

- Características: só compras antes da data de corte
- Alvo: só compras depois da data de corte
- CustomerID fora das características

Fluxo: limpar a base, preparar uma linha por cliente e sempre olhar só para o passado ao criar as características.

Modelo e treinamento

Árvore de Decisão

Modelo principal: profundidade 5

Por que escolhi

- Simples de interpretar
- Boa para testar relações entre as características
- Boa para uma avaliação inicial

Alternativa testada

Profundidade 3

- 1 Corte no tempo: 01/11/2011 (80% do período)
- 2 Antes do corte: características. Depois do corte: alvo
- 3 Divisão 80% treino (3.188) e 20% teste (797), com stratify
- 4 get_dummies de Pais só depois da divisão
- 5 Baseline: sempre prevê "Não comprou novamente" (classe majoritária)

Passos do treinamento, em ordem.

Resultados




Gráfico: acurácia de cada modelo no conjunto de teste (797 clientes).

O modelo supera o baseline.


Acurácia: Atividade 9 → versão revisada

73,15% → 72,40%

Não é só uma piora: transformação depois do split, agrupamento de país e recência deixaram o processo mais rigoroso e o modelo mais simples.

Modelo mais confiável e simples vale mais do que só uma acurácia maior.

Métricas e matriz de confusão



Matriz de confusão no teste (797 clientes): o quadro laranja são os 188 falsos negativos.

Recall · classe "Comproou novamente"

38,56%

O modelo encontra só uma parte dos clientes que realmente voltaram a comprar.

Precision

78,67%

F1-score

0,52

Acurácia

72,40%

Precision e F1 da classe "Comproou novamente", como no relatório do notebook.

O que os erros significam

118

Verdadeiro positivo

Previu que compraria de novo, e comprou.

459

Verdadeiro negativo

Previu que não compraria de novo, e não comprou.

32

Falso positivo

Previu nova compra, mas o cliente não comprou.

188

Falso negativo

Previu que não compraria, mas o cliente comprou.

188

falsos negativos

Clientes que voltariam a comprar, mas o modelo não identificou. É uma oportunidade perdida de relacionamento ou de marketing.

Já o falso positivo seria uma campanha sem retorno.

Cada quadro mostra um tipo de acerto ou de erro no teste (797 clientes).

Overfitting e vazamento de dados

Overfitting: treino × teste

Treino

72,15%

Teste

72,40%

Diferença: -0,25 ponto percentual

Sem sinal de overfitting: os desempenhos são muito próximos, e o teste até ficou um pouco acima.

Acurácia da Árvore de profundidade 5 nos dois conjuntos.

Vazamento: o que conferi

- ✓ Duplicatas removidas antes da divisão
- ✓ Ordem cronológica respeitada
- ✓ Nada do futuro nas características
- ✓ CustomerID fora das características
- ✓ get_dummies de Pais depois do split
- ✓ Nenhuma variável entrega a resposta

Verificação nos clientes do modelo: 0 duplicados entre os 3.985.

Limitações e próximos passos

Limitações

- Recall ainda baixo (38,56%)
- 188 falsos negativos
- Modelo inicial e simples
- Base de um contexto específico de varejo
- Ainda dá para melhorar a identificação de quem tem potencial de recompra

Próximos passos

1. Investigar formas de aumentar o recall, sem perder de vista os outros erros
2. Avançar para a etapa de recomendação de produtos
3. Investigar formas de aumentar o recall
4. Testar outros modelos de Machine Learning, quando aplicável
5. Avaliar a qualidade das recomendações
6. Desenvolver e documentar a etapa de recomendação de produtos

CONCLUSÃO

O modelo aprendeu algo acima do baseline (72,40% contra 61,61%), mas ainda tem limitações, principalmente no recall (38,56%).

O objetivo da etapa foi entender o comportamento do modelo, não só buscar a maior acurácia.

Obrigado! Perguntas?